Reporte de estres

Que tan bien aguanta el estimador de proyectos una conversacion larga, un adjunto pesado, o la misma pregunta repetida

LIDR_6 · Bloque 5 · Gustavo Hernán Pérez Reyes

Este documento resume, en lenguaje simple, los resultados de poner a prueba el servicio de estimación (lidr_5 / LIDR_6) en tres situaciones exigentes: una conversación que se alarga, un documento adjunto cada vez más pesado, y la misma pregunta repetida varias veces. Al final se explica, con palabras llanas, en qué punto el sistema empieza a flaquear y por qué.

Qué significan las tres pruebas — sin jerga:

• **Memoria conversacional:** se simulan conversaciones de 1, 3 y 6 mensajes para ver si el sistema sigue recordándose datos dichos al principio.

• **Adjuntos:** se le manda un PDF de 0, 5, 20, 50 y 100 KB para ver si logra leer todo el documento o pierde partes.

• **Caché:** se repite exactamente la misma pregunta tres veces, para ver si el sistema es lo bastante inteligente como para no volver a pagarle al modelo de IA por la misma respuesta.

1. Lo esencial, de un vistazo

9 seg
responde, en promedio (mediana)

17 seg
en el 5% de casos mas lentos

78%
de las preguntas repetidas se respondieron gratis (cache)

95%
de lo dicho antes, el sistema se acuerda al final

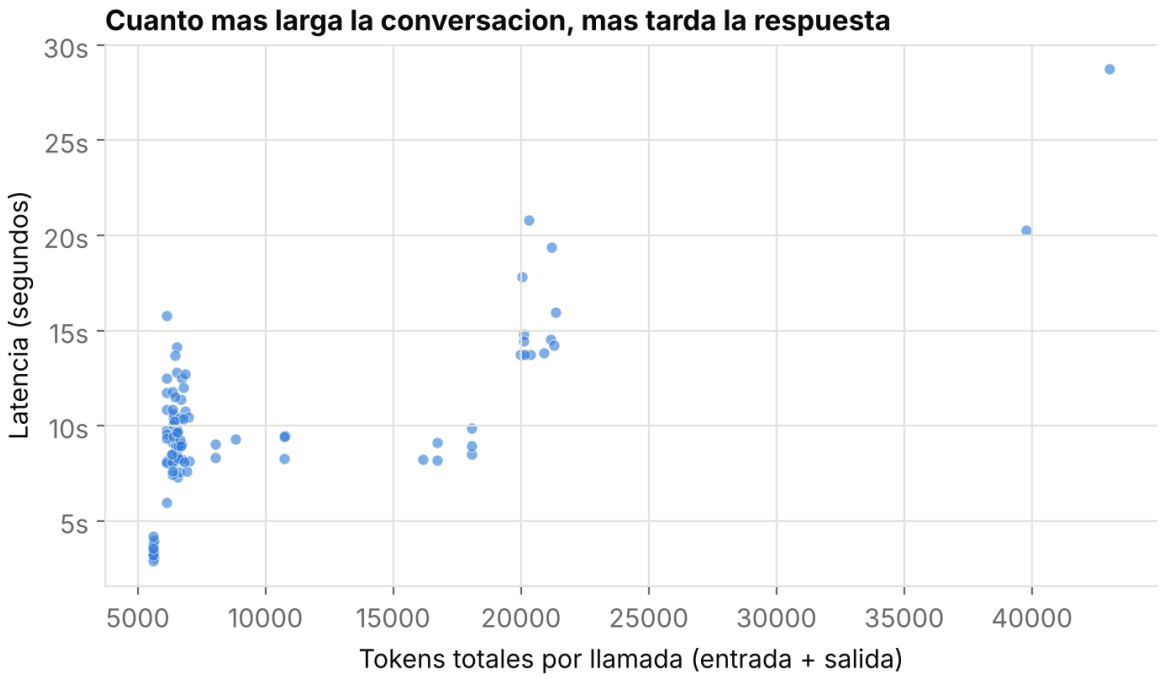
Se hicieron **112 llamadas reales** al modelo de IA (no simuladas): 88 de conversación, 15 con adjuntos y 9 de caché, con un costo total de **USD 0.49**. Una sola llamada falló de forma pasajera (error 502, tipo "intenta de nuevo") sin afectar el resto.

Medida	Resultado	Qué quiere decir
Velocidad de respuesta (mediana)	8.9 segundos	La mitad de las respuestas tardan menos que esto
Velocidad de respuesta (peor 5%)	16.8 segundos	Caso lento, pero no extremo
Acierto de la caché exacta	77.8%	7 de 9 preguntas repetidas no volvieron a pagarle al modelo
Acierto de la caché "inteligente" (semántica)	0%	No hizo falta: la exacta ya resolvió el texto idéntico
Recuerdo de lo dicho antes	92.6%	En promedio, casi todo lo importante se recuerda

2. Los tres gráficos

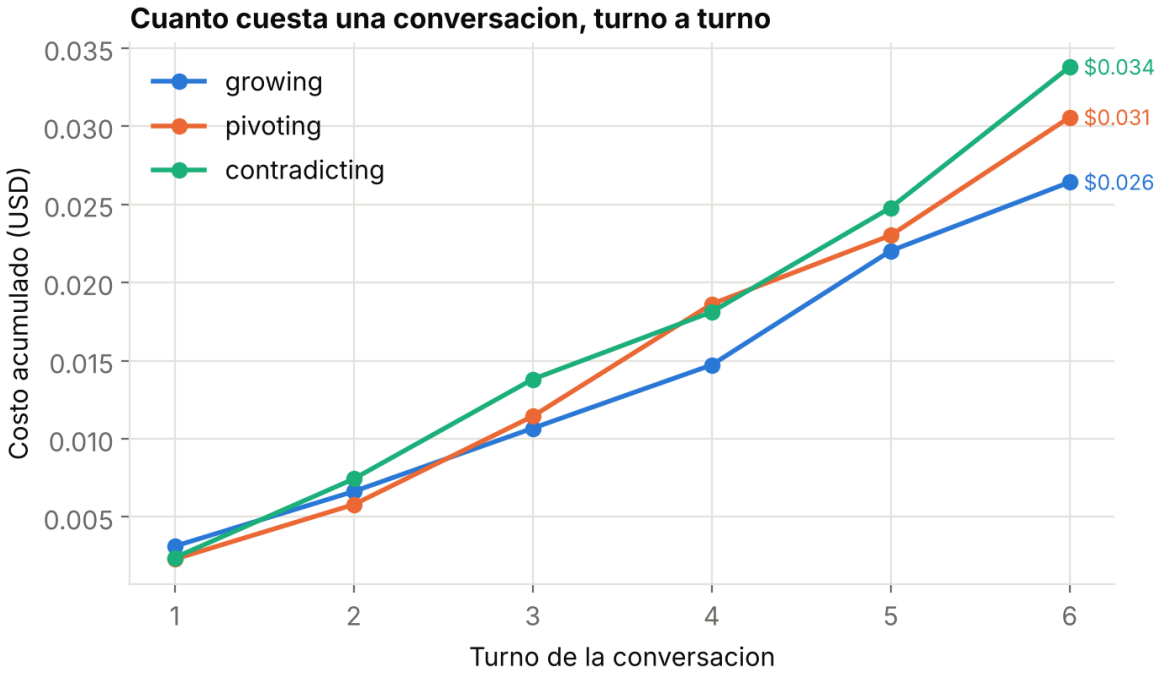
2a. Cuanto mas larga la conversacion, mas tarda la respuesta

Cada punto es una llamada real. Hacia la derecha hay conversaciones mas largas o con adjuntos mas pesados (mas texto que el modelo tiene que leer); hacia arriba, respuestas mas lentas. La tendencia es clara: a mas texto, mas tiempo de espera.



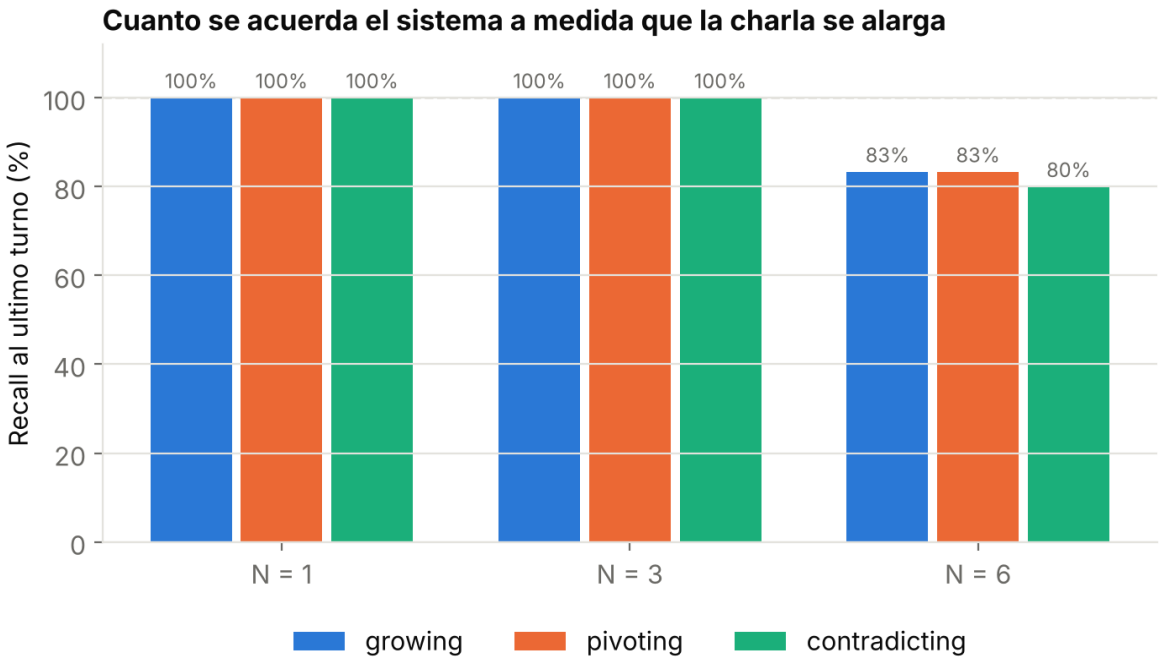
2b. Cuanto cuesta una conversacion, turno a turno

El costo (en dólares) se va sumando con cada mensaje de la conversación: no es que cada turno cueste lo mismo, sino que arrastra todo lo hablado antes. Los tres tipos de conversación probados (creciendo, cambiando de idea, contradiciéndose) terminan en un costo parecido: entre 2.6 y 3.4 centavos de dólar por 6 mensajes.



2c. Cuanto se acuerda el sistema a medida que la charla se alarga

Con conversaciones cortas (1 o 3 mensajes) el sistema se acuerda de todo. A partir de 6 mensajes empieza a olvidar entre un 17% y un 20% de lo dicho al principio — todavía razonable, pero ya no es perfecto.



3. El detalle, escenario por escenario

Las tarjetas de la sección 1 promedian todo junto. Esta tabla desglosa la prueba de memoria conversacional por tipo de conversación (creciendo, cambiando de idea, contradiciéndose) y largo (1, 3 o 6 mensajes) — es donde se ve con claridad en qué punto exacto empieza a fallar.

Tipo de conversación	Largo	Tardanza típica	Costo total	Se acuerda al final
Creciendo	1 mensaje	9.8 s	$0.0099	100%
Creciendo	3 mensajes	10.9 s	$0.0330	100%
Creciendo	6 mensajes	9.0 s	$0.0777	83%
Cambiando de idea	1 mensaje	3.7 s	$0.0069	100%
Cambiando de idea	3 mensajes	8.1 s	$0.0352	100%
Cambiando de idea	6 mensajes	10.4 s	$0.0908	83%
Contradiciéndose	1 mensaje	3.3 s	$0.0073	100%
Contradiciéndose	3 mensajes	8.9 s	$0.0358	100%
Contradiciéndose	6 mensajes	9.2 s	$0.0869	80%

Las filas resaltadas (6 mensajes) son las únicas donde el recuerdo deja de ser perfecto. La tardanza y el costo, en cambio, suben de forma pareja y predecible en todas las filas — no dan ningún salto brusco.

4. En palabras simples: ¿dónde empieza a fallar?

Con conversaciones largas, empieza a olvidar

Hasta 3 mensajes, el sistema recuerda el 100% de lo importante. A partir del sexto mensaje, el recuerdo baja a 80-83%. La sospecha más probable: el sistema guarda la conversación en una "ventana" que no crece sin límite, y los datos viejos solo sobreviven si fueron "anotados" a tiempo antes de salir de esa ventana. Esta prueba mide el síntoma (qué se olvida), no la causa exacta turno por turno — eso requeriría otra prueba más puntual.

Con adjuntos muy pesados, pierde el final del documento

El adjunto de 100 KB vuelve a perder el requisito que estaba al final del documento: el sistema tiene un límite de cuánto texto puede leer de un adjunto, y simplemente corta lo que sobra. Es el primer límite que se rompe, antes que cualquier otra cosa medida en este reporte.

La caché funciona, pero solo en un camino muy específico

Cuando se repite exactamente la misma pregunta por fuera de una conversación, el sistema la reconoce y no vuelve a pagarle al modelo (77.8% de aciertos en esta prueba). Pero esa memoria de "ya respondí esto antes" **no existe** dentro de una conversación con memoria, y el camino con adjuntos tampoco puede usarla. En otras palabras: hoy son **tres caminos separados** que no se tocan entre sí — una conversación larga, con un adjunto, que además repita una pregunta ya hecha, no tiene ningún atajo que cubra las tres cosas a la vez. Ahí es, en el fondo, donde este diseño empieza a mostrar sus costuras.

¿Qué es lo que más pesa: la demora, el costo o la memoria?

La memoria, no la demora ni el costo. Estos dos últimos suben de forma pareja y previsible a medida que la conversación crece (ver la tabla de la sección 3): nunca dan un salto brusco. La memoria, en cambio, es la única que deja de ser perfecta, y lo hace de golpe recién a partir del sexto mensaje, sin ningún aviso previo entre el mensaje 3 y el 6. Por eso, si hay que elegir dónde mirar primero ante una conversación larga, es ahí.

¿Cuándo valdría la pena un cambio de arquitectura más profundo (RAG)?

Cuando se junten dos cosas a la vez: una conversación larga (más de 6-10 mensajes) **y** un dato importante que se haya dicho una sola vez, al principio, sin repetirse después. Ahí es donde la memoria actual (una "ventana" que no guarda todo para siempre) deja de ser confiable, y tendría sentido agregar una búsqueda explícita de ese dato en vez de esperar que sobreviva por su cuenta. Por debajo de ese punto —conversaciones cortas, o datos que se repiten varias veces— el sistema actual ya alcanza, y agregar esa complejidad ahora sería resolver un problema que todavía no existe.

Generado a partir de evals/stress/run.py y evals/stress/results.csv (112 filas, datos reales, sin simular). Ver evals/stress/REPORT.md para la versión técnica completa con todas las tablas.